

10.1 식 (10.13)에 있는 것과 같이 오차벡터의 분산-공분산 행렬이

$$V = [(1-p)I + Jp], \quad 0 < p < 1$$

인 경우에 OLS 추정값과 GLS 추정값이 같음을 증명 하려라.

$$J_p = \mathbf{1}_p \mathbf{1}_p^T, \quad \mathbf{1}_p = [1 \cdots 1]^T \in \mathbb{R}^p$$

$$y = X\beta + \epsilon, \quad \epsilon \sim N(0, (1-p)I + J_p)$$

$$V^{-1/2} = [(1-p)I + Jp]^{-1/2}$$

$$\text{OLS estimator: } (X^T X)^{-1} X^T y$$

$$\text{GLS estimator: } (X^T V^{-1} X)^{-1} X^T V^{-1} y$$

$$\text{WTS: } V^{-1} = I_n \quad \text{or} \quad (X^T X)^{-1} X^T y = (X^T V^{-1} X)^{-1} X^T V^{-1} y$$

$$(X^T V^{-1} X) (X^T X)^{-1} X^T y = (X^T V^{-1} X) (X^T V^{-1} X)^{-1} X^T V^{-1} y \\ \Rightarrow (X^T V^{-1} X) \hat{\beta}^{\text{OLS}} = X^T V^{-1} y$$

$$V^{-1} = [(1-p)I + \mathbf{1}\mathbf{1}^T]^{-1} = cI - d\mathbf{1}\mathbf{1}^T, \quad c, d \in \mathbb{R}$$

$$X^T V^{-1} X = X^T (cI - d\mathbf{1}\mathbf{1}^T) X = cX^T X - dX^T \mathbf{1}\mathbf{1}^T X$$

$$X^T V^{-1} y = X^T (cI - d\mathbf{1}\mathbf{1}^T) y = cX^T y - dX^T \mathbf{1}\mathbf{1}^T y$$

$$\text{LHS: } (X^T V^{-1} X) \hat{\beta}^{\text{OLS}} = (cX^T X - dX^T \mathbf{1}\mathbf{1}^T X) (X^T X)^{-1} X^T y \\ = cX^T y - dX^T \mathbf{1}\mathbf{1}^T \Pi_X y \\ = cX^T y - dX^T \mathbf{1}\mathbf{1}^T y \quad (\because C(\mathbf{1}) \subset C(\Pi_X))$$

$$\text{RHS: } X^T V^{-1} y = cX^T y - dX^T \mathbf{1}\mathbf{1}^T y$$

$$\therefore \text{LHS} = \text{RHS}$$

10.2 선형회귀모형

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad i = 1, 2, \dots, n$$

에서 만약 오차벡터 $\epsilon' = (\epsilon_1, \epsilon_2, \dots, \epsilon_n)$ 의 분산-공분산 행렬이

$$\text{Var}(\epsilon) = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_n^2 \end{bmatrix}$$

인 경우 β_0 와 β_1 의 GLS 추정값을 구하라. 만약 회귀모형이

$$y_i = \beta_1 x_i + \epsilon_i$$

이면 β_1 의 GLS 추정값은 어떻게 되나?

$$X = \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}, \quad X^T V^{-1/2} = \begin{bmatrix} \sigma_1^{-1} & x_1 \sigma_1^{-1} \\ \vdots & \vdots \\ \sigma_n^{-1} & x_n \sigma_n^{-1} \end{bmatrix}, \quad X^T V^{-1} X = \begin{bmatrix} \sum \sigma_i^{-2} & \sum x_i \sigma_i^{-2} \\ \sum x_i \sigma_i^{-2} & \sum x_i^2 \sigma_i^{-2} \end{bmatrix}$$

$$(X^T V^{-1} X)^{-1} = \frac{1}{(\sum \sigma_i^{-2})(\sum x_i^2 \sigma_i^{-2}) - (\sum x_i \sigma_i^{-2})^2} \begin{bmatrix} \sum x_i^2 \sigma_i^{-2} & -\sum x_i \sigma_i^{-2} \\ -\sum x_i \sigma_i^{-2} & \sum \sigma_i^{-2} \end{bmatrix}$$

$$X^T V^{-1} y = \begin{bmatrix} \sigma_1^{-1} & x_1 \sigma_1^{-1} \\ \vdots & \vdots \\ \sigma_n^{-1} & x_n \sigma_n^{-1} \end{bmatrix}^T \begin{bmatrix} \sigma_1^{-1} y_1 \\ \vdots \\ \sigma_n^{-1} y_n \end{bmatrix} = \begin{bmatrix} \sum \sigma_i^{-2} y_i \\ \sum \sigma_i^{-2} x_i y_i \end{bmatrix}$$

$$\therefore \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{bmatrix} = (X^T V^{-1} X)^{-1} X^T V^{-1} y =$$

$$\frac{1}{(\sum \sigma_i^{-2})(\sum x_i^2 \sigma_i^{-2}) - (\sum x_i \sigma_i^{-2})^2} \begin{bmatrix} \sum x_i^2 \sigma_i^{-2} & -\sum x_i \sigma_i^{-2} \\ -\sum x_i \sigma_i^{-2} & \sum \sigma_i^{-2} \end{bmatrix} \begin{bmatrix} \sum \sigma_i^{-2} y_i \\ \sum \sigma_i^{-2} x_i y_i \end{bmatrix}$$

$$\text{If the model is } y = \beta_1 x_i + \epsilon_i$$

$$\hat{\beta}_1 = (X^T V^{-1} X)^{-1} X^T V^{-1} y = \frac{1}{(\sum \sigma_i^{-2})(\sum x_i^2 \sigma_i^{-2}) - (\sum x_i \sigma_i^{-2})^2} \sum \sigma_i^{-2} x_i y_i$$

오차벡터의 분산공분산 행렬이 대각행렬(Diagonal Matrix)이라는 것은, 오차항들 간에 상관관계는 없지만 각각의 분산이 다른 "이분산성(Heteroscedasticity)"가 존재한다는 것을 의미합니다.

이처럼 공분산 행렬이 대각행렬인 경우의 GLS(일반화 최소제곱법)은 각 관측치에 가중치를 부여하는 "가중최소제곱법(Weighted Least Squares)"과 정확히 일치하게 됩니다. 이 때 각 관측치에 부여되는 가중치 w_i 는 분산의 역수입니다.

$$w_i = \frac{1}{\sigma_i^2}$$

1. 절편이 있는 모형의 GLS 추정값 $(y_i = \beta_0 + \beta_1 x_i + \epsilon_i)$

이 모형에서 GLS 추정량은 가중오차제곱합 $S(\beta_0, \beta_1) = \sum_{i=1}^n w_i (y_i - \beta_0 - \beta_1 x_i)^2$ 을 최소화하는 값입니다. 이를 각 파라미터로 편미분하여 0으로 놓고 풀면, 일반적인 OLS 공식에서 모든 데이터 포인트에 가중치 w_i 가 곱해진 형태의 추정값이 도출됩니다.

먼저 가중평균을 다음과 같이 정의합니다.

$$\bar{x}_w = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}, \quad \bar{y}_w = \frac{\sum_{i=1}^n w_i y_i}{\sum_{i=1}^n w_i}$$

그러면 GLS 추정값 $\hat{\beta}_0$ 와 $\hat{\beta}_1$ 은 다음과 같습니다.

$$\bullet \text{ 기울기 추정값 } (\hat{\beta}_1): \quad \hat{\beta}_1 = \frac{\sum_{i=1}^n w_i (x_i - \bar{x}_w)(y_i - \bar{y}_w)}{\sum_{i=1}^n w_i (x_i - \bar{x}_w)^2} = \frac{\sum_{i=1}^n \frac{1}{\sigma_i^2} (x_i - \bar{x}_w)(y_i - \bar{y}_w)}{\sum_{i=1}^n \frac{1}{\sigma_i^2} (x_i - \bar{x}_w)^2}$$

$$\bullet \text{ 절편 추정값 } (\hat{\beta}_0): \quad \hat{\beta}_0 = \bar{y}_w - \hat{\beta}_1 \bar{x}_w$$

2. 절편이 없는 모형의 GLS 추정값 $(y_i = \beta_1 x_i + \epsilon_i)$

원점을 지나는 모형에서는 추정해야 할 파라미터가 β_1 하나뿐입니다. 최소화해야 할 가중오차제곱합은 $S(\beta_1) = \sum_{i=1}^n w_i (y_i - \beta_1 x_i)^2$ 입니다.

이를 β_1 에 대해 편미분하고 0으로 둡니다.

$$\frac{\partial S}{\partial \beta_1} = -2 \sum_{i=1}^n w_i x_i (y_i - \beta_1 x_i) = 0$$

$$\sum_{i=1}^n w_i x_i y_i = \beta_1 \sum_{i=1}^n w_i x_i^2$$

따라서 파라미터 β_1 의 GLS 추정값은 다음과 같이 직관적으로 도출됩니다.

• 절편 없는 모형의 기울기 추정값 $(\hat{\beta}_1)$:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n w_i x_i y_i}{\sum_{i=1}^n w_i x_i^2} = \frac{\sum_{i=1}^n \frac{x_i y_i}{\sigma_i^2}}{\sum_{i=1}^n \frac{x_i^2}{\sigma_i^2}}$$

직관적 의미:

오차의 분산이 다를 때 [이분산성], 우리는 신뢰할 수 있는 분산이 작아 σ_i^2 가 작은 데이터에는 큰 가중치(w_i)를 주고, 신뢰하기 어려운 분산이 커서 오차가 클 수 있는 데이터에는 작은 가중치를 주어 추정치의 효율성을 높게 됩니다. 이것이 WLS가 OLS보다 더 효율적인 (efficient) 추정량을 제공하는 이유입니다.

10-3) 서로 독립인 변수 y_i 들이

$$y_i \sim N(i\theta, i^2\sigma^2), \quad i=1, 2, \dots, n$$

의 분포를 한다면 θ 의 GLS 추정량은 무엇이며 그의 분산은 무엇인가를 구하라.

$$y_i = i\theta + \epsilon_i, \quad \epsilon_i \sim [0, i^2\sigma^2], \quad \text{Var}(y) = \text{diag}(i^2\sigma^2)$$

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_{n-1} \\ y_n \end{bmatrix}, \quad X = \begin{bmatrix} 1 \\ 2 \\ \vdots \\ n-1 \\ n \end{bmatrix} \in \mathbb{R}^{n \times 1}, \quad \beta = [\theta] \in \mathbb{R}^1$$

$$\hat{\beta} = (X^T V^{-1} X)^{-1} X^T V^{-1} y$$

$$V = \text{diag}(i^2\sigma^2), \quad V^{-1} = \text{diag}(i^{-2}\sigma^{-2})$$

$$\text{Let } w_i = i^{-2}\sigma^{-2} \Rightarrow V^{-1} = \text{diag}(w_i)$$

$$(X^T V^{-1} X) = \sum_{i=1}^n w_i i^2, \quad (X^T V^{-1} X)^{-1} = \frac{1}{\sum_{i=1}^n i^2 \sigma_i^{-2}}$$

$$X^T V^{-1} y = \sum_{i=1}^n w_i x_i y_i = \sum_{i=1}^n i^{-2} i^{-1} y_i$$

$$\therefore \hat{\theta} = \frac{\sum_{i=1}^n i^{-2} i^{-1} y_i}{\sum_{i=1}^n i^{-2}} \quad \checkmark$$

(Approach #2)

$$\hat{\theta} = \underset{\theta \in \Omega}{\text{argmin}} \sum_{i=1}^n w_i (y_i - i\theta)^2 = \underset{\theta \in \Omega}{\text{argmin}} L(\theta)$$

$$\partial L / \partial \theta = \sum_{i=1}^n w_i (-i) \cdot 2(y_i - i\theta) = 0$$

$$\Rightarrow \sum_{i=1}^n -w_i i y_i + w_i i^2 \theta = 0$$

$$\Rightarrow \theta \sum_{i=1}^n w_i i^2 = \sum_{i=1}^n w_i i y_i$$

$$\therefore \hat{\theta}_{GLS} = \frac{\sum_{i=1}^n i^{-2} \sigma_i^{-2} i y_i}{\sum_{i=1}^n i^{-2} \sigma_i^{-2} i^2} = \frac{\sum_{i=1}^n i^{-1} \sigma_i^{-2} y_i}{\sum_{i=1}^n i \sigma_i^{-2}} = \frac{\sigma_i^{-2} \sum_{i=1}^n i^{-1} y_i}{\sigma_i^{-2} \sum_{i=1}^n i} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i}{i} \right)$$

10.4) 선형회귀모형, $y = X\beta + \epsilon$ 에서

$$y \sim N(X\beta, V\sigma^2)$$

V : 알고 있는 $n \times n$ 양정치 행렬 (positive definite matrix)

X : $n \times (k+1)$ 행렬로 계수는 $k+1$

$$b^*: (X^T V^{-1} X)^{-1} X^T V^{-1} y$$

인 경우에 다음을 증명하라.

$$(1) \theta = (y - Xb^*)^T V^{-1} (y - Xb^*) / \sigma^2 \sim \chi^2(n-k-1)$$

(2) $y^* = Xb^* = Py$ 일 때에 P 는 멱등 (idempotent) 행렬이나, 일반적으로 대칭 (symmetric) 행렬은 아니다.

(1) Expansion of θ :

$$(y - Xb^*) = (I - X(X^T V^{-1} X)^{-1} X^T V^{-1}) y$$

$$(y - Xb^*)^T V^{-1} (y - Xb^*) = y^T [I - X(X^T V^{-1} X)^{-1} X^T V^{-1}] V^{-1} [I - X(X^T V^{-1} X)^{-1} X^T V^{-1}] y$$

$$= y^T V^{-1} y + y^T V^{-1} X (X^T V^{-1} X)^{-1} X^T V^{-1} y$$

$$\text{Let } y' = V^{-1/2} y \text{ and } X' = V^{-1/2} X$$

$$(y - Xb^*)^T V^{-1} (y - Xb^*) = (y')^T (y') + (y')^T X' (X'^T X')^{-1} X'^T y'$$

$$= y'^T [I_n - \Pi_{X'}] y'$$

$$y' = V^{-1/2} y \sim N(V^{-1/2} X\beta, \sigma^2 I_n)$$

$$\therefore \Sigma = \text{Var}(y') = \sigma^2 I_n$$

We know the quadratic form $y'^T A y' \sim \chi^2(r)$ if $A\Sigma = A \cdot \text{Var}(y')$ is idempotent.

$$(y')^T \left(\frac{I_n - \Pi_{X'}}{\sigma^2} \right) (y') \sim \chi^2(r; \delta) \Leftrightarrow A\Sigma = \left(\frac{I_n - \Pi_{X'}}{\sigma^2} \right) \text{Var}(y') \text{ is idempotent.}$$

$$(I_n - \Pi_{X'}) / \sigma^2 \cdot \sigma^2 I_n = I_n - \Pi_{X'} \text{ is a projection onto } C(X')^\perp \therefore A\Sigma \text{ is idempotent.}$$

$$r = \text{rank}(I_n - \Pi_{X'}) = \text{trace}(I_n - \Pi_{X'}) = \text{trace}(I_n) - \text{trace}(\Pi_{X'})$$

$$= n - \text{trace}(X'(X'^T X')^{-1} X'^T) = n - \text{trace}(X'^T X' (X'^T X')^{-1})$$

$$= n - \text{trace}(I_{k+1})$$

$$= n - k - 1$$

$$\delta = E[y']^T A E[y'] = [V^{-1/2} X\beta]^T \left(\frac{I_n - \Pi_{X'}}{\sigma^2} \right) [V^{-1/2} X\beta] = 0 \because (I_n - \Pi_{X'}) V^{-1/2} X = 0$$

$$\therefore \theta = (y - Xb^*)^T V^{-1} (y - Xb^*) \sim \chi^2(n-k-1)$$

$$(2) y^* = Xb^* = Py, \quad b^* = (X^T V^{-1} X)^{-1} X^T V^{-1} y$$

$$\therefore Xb^* = X(X^T V^{-1} X)^{-1} X^T V^{-1} y = Py$$

$$\therefore P = X(X^T V^{-1} X)^{-1} X^T V^{-1}$$

$$P^2 = X(X^T V^{-1} X)^{-1} X^T V^{-1} X(X^T V^{-1} X)^{-1} X^T V^{-1}$$

$$= X(X^T V^{-1} X)^{-1} X^T V^{-1}$$

$$= P$$

$\therefore P$ is idempotent.

$$P^T = V^{-1} X(X^T V^{-1} X)^{-1} X^T \neq X(X^T V^{-1} X)^{-1} X^T V^{-1} = P$$

if $V \neq I_n$. $\therefore P$ is not typically symmetric ✓✓

10.5) 선형회귀모형

$$y = X\beta + \epsilon, \quad \text{Var}(\epsilon) = V\sigma^2$$

에서 β 의 GLS의 추정량을 b^* 라 할 때 $\rho^* b^*$ 와 $q^* b^*$ 의 공분산을 구하라.

$$b^* = (X^T V^{-1} X)^{-1} X^T V^{-1} y$$

$$\text{cov}(q^* b^*, \rho^* b^*) = q^* \text{cov}(b^*, b^*) \rho$$

$$= q^* \text{Var}(b^*) \rho$$

$$= q^* (X^T V^{-1} X)^{-1} X^T V^{-1} \text{Var}(y) V^{-1} X(X^T V^{-1} X)^{-1} \rho$$

$$= \sigma^2 q^* (X^T V^{-1} X)^{-1} X^T V^{-1} V V^{-1} X(X^T V^{-1} X)^{-1} \rho$$

$$= \sigma^2 q^* (X^T V^{-1} X)^{-1} \rho \quad \checkmark$$

10.6) 다변량 선형회귀모형식 (식 (10.8)과 (10.9))에서

$$b^* = (Z^T \Omega^{-1} Z)^{-1} Z^T \Omega^{-1} y$$

$$= (Z^T Z)^{-1} Z^T y = b$$

임이 밝혀져서, 방정식별로 OLS 추정을 하나 같이 묶어서 GLS 추정을 하나, 결과가 같은 것으로 판명되었다. 이 결과의 증명을 다음의 순서대로 밝힘으로써 증명하라. $\Sigma = (\sigma_{ij})$ 일 때 $\Sigma^{-1} = (\sigma^{ij})$ 로 표시하자.

$$(1) Z^T \Omega^{-1} Z = \begin{bmatrix} \sigma^{11} X'X & \sigma^{12} X'X & \dots & \sigma^{1g} X'X \\ & \sigma^{22} X'X & \dots & \sigma^{2g} X'X \\ & & \ddots & \\ & & & \sigma^{gg} X'X \end{bmatrix}$$

$$(2) (Z^T \Omega^{-1} Z)^{-1} = \begin{bmatrix} \sigma_{11} (X'X)^{-1} & \sigma_{12} (X'X)^{-1} & \dots & \sigma_{1g} (X'X)^{-1} \\ & \sigma_{22} (X'X)^{-1} & \dots & \sigma_{2g} (X'X)^{-1} \\ & & \ddots & \\ & & & \sigma_{gg} (X'X)^{-1} \end{bmatrix}$$

$$(3) Z^T \Omega^{-1} y = \begin{bmatrix} \sum_{h=1}^g \sigma^{1h} X' y_h \\ \vdots \\ \sum_{h=1}^g \sigma^{gh} X' y_h \end{bmatrix}$$

$$(4) \sum_{h=1}^g \sigma_{ih} \sigma^{hi} = 1, \quad i=j$$

$$= 0, \quad i \neq j$$

$$(5) b^* = \begin{bmatrix} b_1^* \\ b_2^* \\ \vdots \\ b_g^* \end{bmatrix} = (Z^T \Omega^{-1} Z)^{-1} Z^T \Omega^{-1} y \text{로부터}$$

$$b_i^* = \sum_{h=1}^g \sigma_{ih} (X'X)^{-1} \sum_{j=1}^g \sigma^{hj} X' y_j = (X'X)^{-1} X' y_i$$

p 328-329

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_g \end{bmatrix} = \begin{bmatrix} X & 0 & \cdots & 0 & 0 \\ 0 & X & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & X & 0 \\ 0 & 0 & \cdots & 0 & X \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_g \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_g \end{bmatrix}$$

$$\text{이를 간단하게 } y = Z\beta + \epsilon \quad (10.18)$$

... 벡터 ϵ 의 분산-공분산 행렬을 구해보면

$$\begin{aligned} \text{Var}(\epsilon) &= \begin{bmatrix} E[\epsilon_1 \epsilon_1'] & E[\epsilon_1 \epsilon_2'] & \cdots & E[\epsilon_1 \epsilon_g'] \\ & E[\epsilon_2 \epsilon_2'] & \cdots & E[\epsilon_2 \epsilon_g'] \\ & & \ddots & \vdots \\ & & & E[\epsilon_g \epsilon_g'] \end{bmatrix} \\ &= \begin{bmatrix} I\sigma_1^2 & I\sigma_{12} & \cdots & I\sigma_{1g} \\ & I\sigma_2^2 & \cdots & I\sigma_{2g} \\ & & \ddots & \vdots \\ & & & I\sigma_g^2 \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1g} \\ & \sigma_2^2 & \cdots & \sigma_{2g} \\ & & \ddots & \vdots \\ & & & \sigma_g^2 \end{bmatrix} \otimes I = \Sigma \otimes I = \Omega \quad (10.19) \end{aligned}$$

이 된다. 여기서 사용된 $\otimes$ 는 크로네카곱 (kronecker multiplication) 을 나타내는 기호로 $A \otimes I = (a_{ij}) \otimes I = (a_{ij} I)$ 와 같은 기능을 가진다. 식 (10.14) 에서 떨어진 행렬 Ω 는 $gn \times gn$ 의 대칭행렬이다. 결과적으로

$$\text{Var}(\epsilon) = \Omega + \sigma^2 I$$

이므로, 모형 (10.18) 의 β 추정에는 GLS 추정방법을 사용하여야 한다. 따라서 β 의 추정량은

$$b^* = (Z' \Omega^{-1} Z)^{-1} Z' \Omega^{-1} y = \begin{bmatrix} b_1^* \\ b_2^* \\ \vdots \\ b_g^* \end{bmatrix}$$

로 표현된다.

$$(A \otimes B)(C \otimes D) = AC \otimes BD$$

$$(A \otimes B)' = A' \otimes B'$$

$$(A \otimes B)'(A \otimes B) = A'A \otimes B'B = I$$

$$(1) Z' \Omega^{-1} Z = Z'(\Sigma \otimes I)Z = Z'(\Sigma^{-1} \otimes I)Z$$

$$\begin{bmatrix} X^T & 0 & \cdots & 0 \\ 0 & X^T & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & X^T \end{bmatrix} \begin{bmatrix} \sigma^{-1} I & \sigma^{-12} I & \cdots & \sigma^{-1g} I \\ \sigma^{-21} I & \sigma^{-22} I & \cdots & \sigma^{-2g} I \\ \vdots & \vdots & \ddots & \vdots \\ \sigma^{-g1} I & \sigma^{-g2} I & \cdots & \sigma^{-gg} I \end{bmatrix} \begin{bmatrix} X & 0 & \cdots & 0 \\ 0 & X & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & X \end{bmatrix}$$

$$= \begin{bmatrix} \sigma^{-1} X^T X & \sigma^{-12} X^T X & \cdots & \sigma^{-1g} X^T X \\ \sigma^{-21} X^T X & \sigma^{-22} X^T X & \cdots & \sigma^{-2g} X^T X \\ \vdots & \vdots & \ddots & \vdots \\ \sigma^{-g1} X^T X & \sigma^{-g2} X^T X & \cdots & \sigma^{-gg} X^T X \end{bmatrix}$$

$$\begin{aligned} (2) (Z' \Omega^{-1} Z)^{-1} &= (\Omega^{-1} \otimes (X^T X)^{-1})^{-1} \\ &= \Omega \otimes (X^T X)^{-1} \\ &= (\Sigma \otimes I) \otimes (X^T X)^{-1} \\ &= (\Sigma \otimes (X^T X)^{-1}) \end{aligned}$$

$$= \begin{bmatrix} \sigma_{11}(X^T X)^{-1} & \sigma_{12}(X^T X)^{-1} & \cdots & \sigma_{1g}(X^T X)^{-1} \\ \sigma_{21}(X^T X)^{-1} & \sigma_{22}(X^T X)^{-1} & \cdots & \sigma_{2g}(X^T X)^{-1} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{g1}(X^T X)^{-1} & \sigma_{g2}(X^T X)^{-1} & \cdots & \sigma_{gg}(X^T X)^{-1} \end{bmatrix}$$

$$(3) Z' \Omega^{-1} y = Z'(\Sigma \otimes I)^{-1} y$$

$$\begin{bmatrix} X^T & 0 & \cdots & 0 \\ 0 & X^T & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & X^T \end{bmatrix} \begin{bmatrix} \sigma^{-1} I & \sigma^{-12} I & \cdots & \sigma^{-1g} I \\ \sigma^{-21} I & \sigma^{-22} I & \cdots & \sigma^{-2g} I \\ \vdots & \vdots & \ddots & \vdots \\ \sigma^{-g1} I & \sigma^{-g2} I & \cdots & \sigma^{-gg} I \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_g \end{bmatrix}$$

$$= \begin{bmatrix} X^T & 0 & \cdots & 0 \\ 0 & X^T & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & X^T \end{bmatrix} \begin{bmatrix} \sum_{h=1}^g \sigma^{-1h} X^T y_h \\ \vdots \\ \sum_{h=1}^g \sigma^{-gh} X^T y_h \end{bmatrix} = \begin{bmatrix} \sum_{h=1}^g \sigma^{-1h} X^T y_h \\ \vdots \\ \sum_{h=1}^g \sigma^{-gh} X^T y_h \end{bmatrix}, \quad \begin{matrix} y_1 \in \mathbb{R}^n \\ y \in \mathbb{R}^{gn} \end{matrix}$$

$$\begin{aligned} (4) \sum_{h=1}^g \sigma_{1h} \sigma^{-hj} &= \sum_{h=1}^g e_1' \Sigma e_h \cdot e_h' \Sigma^{-1} e_j \\ &= e_1' \Sigma \Sigma^{-1} e_j = e_1' e_j = \begin{cases} 1 & \text{if } i=j \\ 0 & \text{if } i \neq j \end{cases} \end{aligned}$$

$$(5) b^* = (Z' \Omega^{-1} Z)^{-1} Z' \Omega^{-1} y$$

$$\begin{bmatrix} \sigma_{11}(X^T X)^{-1} & \sigma_{12}(X^T X)^{-1} & \cdots & \sigma_{1g}(X^T X)^{-1} \\ \sigma_{21}(X^T X)^{-1} & \sigma_{22}(X^T X)^{-1} & \cdots & \sigma_{2g}(X^T X)^{-1} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{g1}(X^T X)^{-1} & \sigma_{g2}(X^T X)^{-1} & \cdots & \sigma_{gg}(X^T X)^{-1} \end{bmatrix} \begin{bmatrix} \sum_{h=1}^g \sigma^{-1h} X^T y_h \\ \vdots \\ \sum_{h=1}^g \sigma^{-gh} X^T y_h \end{bmatrix}$$

$$= \begin{bmatrix} \sum_{j=1}^g \sum_{h=1}^g \sigma_{1j} \sigma^{-jh} (X^T X)^{-1} X^T y_j \\ \vdots \\ \sum_{j=1}^g \sum_{h=1}^g \sigma_{gj} \sigma^{-jh} (X^T X)^{-1} X^T y_j \end{bmatrix} = \begin{bmatrix} \sum_{j=1}^g \sigma_{1j} \sigma^{-j1} (X^T X)^{-1} X^T y_1 \\ \vdots \\ \sum_{j=1}^g \sigma_{gj} \sigma^{-jg} (X^T X)^{-1} X^T y_g \end{bmatrix} = \begin{bmatrix} (X^T X)^{-1} X^T y_1 \\ \vdots \\ (X^T X)^{-1} X^T y_g \end{bmatrix}$$

$$\therefore b_i^* = (X^T X)^{-1} X^T y_i$$

p 330

$$\begin{aligned} b^* &= (Z' \Omega^{-1} Z)^{-1} (Z' \Omega^{-1} y) \\ &= (Z'(\Sigma \otimes I)^{-1} Z)^{-1} (Z'(\Sigma \otimes I)^{-1} y) \\ &= (Z'(\Sigma^{-1} \otimes I)Z)^{-1} (Z'(\Sigma^{-1} \otimes I)y) \\ &= (Z' \Sigma^{-1} \otimes Z')^{-1} (Z' \Sigma^{-1} \otimes y) \\ &= (\Sigma^{-1} \otimes (Z Z'))^{-1} (\Sigma^{-1} \otimes (Z' y)) \\ &= (\Sigma \otimes (Z Z'))^{-1} (\Sigma \otimes (Z' y)) \\ &= (\Sigma \Sigma^{-1}) \otimes (Z Z')^{-1} Z' y \\ &= I \otimes (Z Z')^{-1} Z' y \\ &= (Z Z')^{-1} Z' y = b \end{aligned}$$

10.7) 다변량 선형회귀모형

$$y_1 = x_1 \beta_1 + \epsilon_1, \quad y_2 = x_2 \beta_2 + \epsilon_2$$

$$\text{Var}(\epsilon_i) = \begin{pmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{pmatrix} \otimes I$$

$$\sigma_{12} = \rho \sqrt{\sigma_{11} \sigma_{22}}$$

에서 $b^* = (Z' \Omega Z)^{-1} Z' \Omega^{-1} y$ 와 $\text{Var}(b^*)$ 을 $x_1, x_2, \rho, \sigma_{11}, \sigma_{22}$ 와 y_1, y_2 를 사용하여 표현하여라.

$$Z = \begin{pmatrix} x_1 & 0 \\ 0 & x_2 \end{pmatrix}, \quad \Omega = \Sigma \otimes I = \text{Var}(\epsilon_i)$$

$$\Omega^{-1} = \Sigma^{-1} \otimes I_n = \frac{1}{\sigma_{11} \sigma_{22} - \sigma_{12}^2} \begin{bmatrix} \sigma_{22} & -\sigma_{12} \\ -\sigma_{21} & \sigma_{11} \end{bmatrix} \otimes I$$

$$= \frac{1}{\sigma_{11} \sigma_{22} (1 - \rho^2)} \begin{bmatrix} \sigma_{22} & -\sigma_{12} \\ -\sigma_{21} & \sigma_{11} \end{bmatrix} \otimes I$$

$$(Z' \Omega^{-1} Z)^{-1} = (Z' \Sigma^{-1} \otimes I Z)^{-1} = \Sigma \otimes (Z' Z)^{-1} = \begin{bmatrix} \sigma_{11} (x_1' x_1)^{-1} & \sigma_{12} (x_1' x_2)^{-1} \\ \sigma_{21} (x_2' x_1)^{-1} & \sigma_{22} (x_2' x_2)^{-1} \end{bmatrix}$$

$$Z' \Omega^{-1} y = \begin{bmatrix} x_1' & 0 \\ 0 & x_2' \end{bmatrix} \cdot \frac{1}{\sigma_{11} \sigma_{22} (1 - \rho^2)} \begin{bmatrix} \sigma_{22} & -\sigma_{12} \\ -\sigma_{21} & \sigma_{11} \end{bmatrix} \otimes I \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}$$

$$= \frac{1}{\sigma_{11} \sigma_{22} (1 - \rho^2)} \begin{bmatrix} x_1' (\sigma_{22} y_1 - \sigma_{12} y_2) \\ x_2' (-\sigma_{21} y_1 + \sigma_{11} y_2) \end{bmatrix}$$

$$\hat{\beta} = (Z' \Omega^{-1} Z)^{-1} Z' \Omega^{-1} y = \frac{1}{\sigma_{11} \sigma_{22} (1 - \rho^2)} \begin{bmatrix} \sigma_{11} (x_1' x_1)^{-1} & \sigma_{12} (x_1' x_2)^{-1} \\ \sigma_{21} (x_2' x_1)^{-1} & \sigma_{22} (x_2' x_2)^{-1} \end{bmatrix} \begin{bmatrix} x_1' (\sigma_{22} y_1 - \sigma_{12} y_2) \\ x_2' (-\sigma_{21} y_1 + \sigma_{11} y_2) \end{bmatrix}$$

$$= \frac{1}{\sigma_{11} \sigma_{22} (1 - \rho^2)} \begin{bmatrix} \sigma_{11} (x_1' x_1)^{-1} x_1' (\sigma_{22} y_1 - \sigma_{12} y_2) & \sigma_{12} (x_1' x_2)^{-1} x_2' (-\sigma_{21} y_1 + \sigma_{11} y_2) \\ \sigma_{21} (x_2' x_1)^{-1} x_1' (\sigma_{22} y_1 - \sigma_{12} y_2) & \sigma_{22} (x_2' x_2)^{-1} x_2' (-\sigma_{21} y_1 + \sigma_{11} y_2) \end{bmatrix}$$

10.10) 적선회귀모형

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad x_i > 0, \quad i = 1, 2, \dots, n$$

에서 $\epsilon_i = \rho \epsilon_{i-1} + \delta_i$, $\delta_i \sim N(0, \sigma_\delta^2)$ 이고 δ_i 들은 서로 독립이라고 가정한다. 만약 b_1 이 β_1 의 OLS 추정량이라면 $\rho > 0$ 일 때에 $\text{Var}(b_1)$ 은 $\rho = 0$ 일 때의 $\text{Var}(b_1)$ 보다 더 큼을 증명하여라.

$$\text{If } \rho = 0, \quad \epsilon_i = \delta_i \stackrel{iid}{\sim} N(0, \sigma_\delta^2)$$

$$\therefore \hat{\beta}_1 = \frac{\sum x_i y_i}{\sum x_i^2} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$\text{Var}(\hat{\beta}_1) = \text{Var}\left(\frac{\sum (x_i - \bar{x}) y_i}{\sum (x_i - \bar{x})^2}\right) = \frac{1}{\sum (x_i - \bar{x})^2} \sum (x_i - \bar{x})^2 \text{Var}(y_i) = \frac{\sigma^2}{\sum x_i^2}$$

$$\rho = E[XY] - E[X]E[Y] = E[(X - \bar{X})(Y - \bar{Y})]$$

ϵ_0 is not defined. Suppose that $\epsilon_0 = 0$

$$\epsilon_0 = 0$$

$$\epsilon_1 = \rho \epsilon_0 + \delta_1$$

$$\epsilon_2 = \rho(\rho \epsilon_0 + \delta_1) + \delta_2 = \rho^2 \epsilon_0 + \rho \delta_1 + \delta_2$$

⋮

$$\epsilon_n = \rho^n \epsilon_0 + \sum_{i=1}^n \rho^{i-1} \delta_i$$

$$\text{Var}(\epsilon_n) = \sum_{i=1}^n \rho^{2(i-1)} \sigma^2$$

$$\text{Cov}(\epsilon_n, \epsilon_m) = \text{Cov}\left(\sum_{i=1}^n \rho^{i-1} \delta_i, \sum_{j=1}^m \rho^{j-1} \delta_j\right) \quad (n > m)$$

$$= \text{Cov}\left(\sum_{i=1}^m \rho^{i-1} \delta_i, \sum_{j=1}^m \rho^{j-1} \delta_j\right) = \sum_{i=1}^m \rho^{2(i-1)} \sigma^2 = \text{Var}(\epsilon_m)$$

$$\text{If } \rho > 0, \quad \text{Var}(b_1) = \text{Var}\left(\frac{\sum (x_i - \bar{x}) y_i}{\sum x_i^2}\right)$$

$$= \frac{1}{\sum x_i^2} \text{Var}\left(\sum (x_i - \bar{x}) y_i\right)$$

$$= \frac{1}{\sum x_i^2} \sum_{i=1}^n \sum_{j=1}^n (x_i - \bar{x})(x_j - \bar{x}) \cdot \text{Cov}(y_i, y_j)$$

Gemini 3.1. pro answer

(...)

② $\rho > 0$ 일 때의 오차항 성질

오차항이 $\epsilon_i = \rho \epsilon_{i-1} + \delta_i$ 를 따르고 정상성 ($|\rho| < 1$) 을 만족한다고 가정할 때, 오차항의 자기분산과 자기공분산은 다음과 같습니다.

$$\text{Var}(\epsilon_i) = \frac{\sigma_\delta^2}{1 - \rho^2}, \quad \text{Cov}(\epsilon_i, \epsilon_j) = \rho^{|j-i|} \frac{\sigma_\delta^2}{1 - \rho^2}$$

③ $\rho > 0$ 일 때의 OLS 추정량 분산 전개

자기상관 (auto correlation) 이 존재하므로 b_1 의 분산을 구할 때 공분산 항을 포함하여 전개해야 합니다.

$$\text{Var}(b_1 | \rho > 0) = \frac{\text{Var}\left(\sum_{i=1}^n (x_i - \bar{x}) \epsilon_i\right)}{\left(\sum_{i=1}^n (x_i - \bar{x})^2\right)^2}$$

분자를 전개하면 이중 시그마 형태가 나옵니다.

$$\text{Var}\left(\sum_{i=1}^n (x_i - \bar{x}) \epsilon_i\right) = \sum_{i=1}^n (x_i - \bar{x})^2 \cdot \text{Var}(\epsilon_i) + 2 \sum_{i=1}^{n-1} \sum_{j=i+1}^n (x_i - \bar{x})(x_j - \bar{x}) \cdot \text{Cov}(\epsilon_i, \epsilon_j)$$

10.11) 만약

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad i = 1, 2, 3$$

$$E[\epsilon_i] = 0$$

$$\text{Var}(\epsilon_i) = \sigma^2$$

여기서 ② 번에서 구한 분산과 공분산을 대입하여 전체 식을 정리합니다.

$$\text{Var}(b_1 | \rho > 0) = \frac{\sigma^2 / (1 - \rho^2)}{\sum_{i=1}^n (x_i - \bar{x})^2} \left[1 + 2 \sum_{i=1}^{n-1} \sum_{j=i+1}^n \rho^{j-i} \frac{(x_i - \bar{x})(x_j - \bar{x})}{\sum_{k=1}^n (x_k - \bar{x})^2} \right]$$

으로

$$V = \begin{bmatrix} 1 & \rho a & \rho \\ \rho a & a^2 & \rho a \\ \rho & \rho a & 1 \end{bmatrix}, \quad 0 < \rho < 1$$

④ 분산 비교 및 증명 완료

도출된 두 분산 식을 비교하면 $\rho > 0$ 일 때 분산이 커지는 두 가지 요인을 확인할 수 있습니다.

1. 기본 분산 팽창: $\rho > 0$ 이므로 $\frac{1}{1 - \rho^2} > 1$ 입니다. 즉, 같은 값의 기본 분산항 자체가 $\rho = 0$ 일 때의 σ^2 보다 커집니다.

2. 교차곱 (cross-product) 항의 가산: 시계열 데이터나 점진적으로 증가하는 변수 x_i 의 경우 (문제의 $x_i > 0$ 조건 하에서 일반적으로 관찰되는 특성), 이웃한 시점의 $(x_i - \bar{x})(x_j - \bar{x})$ 값은 지배적으로 양수 (+)가 됩니다. 여기에 $\rho > 0$ 에 의해 $\rho^{j-i} > 0$ 이므로 같은 안의 값이 1보다 커지게 됩니다.

이며, ρ 와 a 는 이차의 상수라고 하자. x_i 의 값이 $x_1 = -1, x_2 = 0, x_3 = 1$ 을 취할 때 β_0 와 β_1 의 GLS 추정값이 다음과 같음을 증명하라.

$$\begin{bmatrix} b_0^* \\ b_1^* \end{bmatrix} = \begin{bmatrix} \frac{1}{r} \{ (a^2 - \rho^2) y_1 + (1 - 2\rho + \rho^2) y_2 + (a^2 + \rho) y_3 \} \\ -\frac{1}{2} y_1 + \frac{1}{2} y_3 \end{bmatrix}$$

여기서 $r = 1 + \rho + 2a^2 - 4\rho$ 이다.

$$\hat{\beta}^{GLS} = (X^T V^{-1} X)^{-1} X^T V^{-1} y$$

* Gaussian Elimination Method.

$$\left[\begin{array}{ccc|ccc} 1 & \rho a & \rho & 1 & 0 & 0 \\ \rho a & a^2 & \rho a & 0 & 1 & 0 \\ \rho & \rho a & 1 & 0 & 0 & 1 \end{array} \right] \Rightarrow \left[\begin{array}{ccc|ccc} 1 & 0 & 0 & a & b & c \\ 0 & 1 & 0 & d & e & f \\ 0 & 0 & 1 & g & h & i \end{array} \right]$$

* Cofactor matrix: $C_{ij} = (-1)^{i+j} M_{ij}$ (M_{ij} : minor. Determinant of the 2×2 submatrix that remains after crossing out the i th row & j th column)

$$C_{11}: a^2 - \rho^2 a^2 = a^2 (1 - \rho^2)$$

$$C_{12}: -(pa - \rho^2 a) = -\rho a (1 - \rho)$$

$$C_{13}: \rho^2 a^2 - \rho a^2 = \rho a^2 (\rho - 1) = -\rho a^2 (1 - \rho)$$

$$C_{21}: -(pa - \rho^2 a) = -\rho a (1 - \rho)$$

$$C_{22}: 1 - \rho^2$$

$$C_{23}: -(pa - \rho^2 a) = -\rho a (1 - \rho)$$

$$C_{31}: \rho^2 a^2 - a^2 \rho = \rho a^2 (\rho - 1) = -\rho a^2 (1 - \rho)$$

$$C_{32}: -(pa - \rho^2 a) = -\rho a (1 - \rho)$$

$$C_{33}: a^2 - \rho^2 a^2 = a^2 (1 - \rho^2)$$

$$\begin{aligned} \det(A) &= 1 \cdot (a^2 - \rho^2 a^2) - \rho a (pa - \rho^2 a) + \rho (\rho^2 a^2 - a^2 \rho) \\ &= a^2 (1 - \rho^2) - \rho^2 a^2 (1 - \rho) + \rho^2 a^2 (\rho - 1) \\ &= a^2 (1 - \rho)(1 + \rho) - 2\rho^2 a^2 (1 - \rho) \\ &= a^2 (1 + \rho - 2\rho^2)(1 - \rho) \\ &= a^2 (1 - \rho)(1 + 2\rho)(1 - \rho)^2 \\ &= a^2 (1 + 2\rho)(1 - \rho)^2 \end{aligned}$$

$$C = \begin{bmatrix} a^2(1-\rho^2) & -\rho a(1-\rho) & -\rho a^2(1-\rho) \\ -\rho a(1-\rho) & 1-\rho^2 & -\rho a(1-\rho) \\ -\rho a^2(1-\rho) & -\rho a(1-\rho) & a^2(1-\rho^2) \end{bmatrix} : \text{Cofactor matrix.}$$

$$A^{-1} = \frac{1}{\det(A)} C^T = \frac{1}{(1-\rho)(1+2\rho)} \begin{bmatrix} 1+\rho & -\rho/a & -\rho \\ -\rho/a & (1+\rho)a^2 & -\rho/a \\ -\rho & -\rho/a & 1+\rho \end{bmatrix}$$

$$X'V^{-1}X = \frac{1}{(1-\rho)(1+2\rho)} \begin{bmatrix} \frac{n}{a^2} & 0 \\ 0 & 2(1+\rho) \end{bmatrix}$$

$$X'V^{-1}y = \frac{1}{(1-\rho)(1+2\rho)} \begin{bmatrix} \frac{a-\rho}{a}y_1 + \frac{1+\rho-2a\rho}{a^2}y_2 + \frac{a-\rho}{a}y_3 \\ -(1+2\rho)y_1 + (1+2\rho)y_3 \end{bmatrix}$$

$$\begin{aligned} b^* &= (X'V^{-1}X)^{-1}X'V^{-1}y \\ &= \begin{bmatrix} \frac{1}{2}[(a^2-\rho^2)y_1 + (1-2a\rho+\rho)y_2 + (a^2-\rho^2)y_3] \\ -\frac{1}{2}y_1 + \frac{1}{2}y_3 \end{bmatrix} \end{aligned}$$

* Key Takeaways.

→ understand how to calculate the inverse matrix of V using the cofactor matrix.

→ Inverse matrix 구하는 것이 오래 걸리기 때문에 시험에 나올 것 같지는 않다.

10.12 만약 $y_i, i=1,2,\dots,n$ 가 서로 독립인 확률변수로서 기대값 θ 와 분산 σ^2/w_i 를 갖는다고 하자. θ 의 BLUE를 구하고, 그 최소분산(minimum variance)이 무엇인지를 밝혀라.

$$y = \theta + \epsilon, \epsilon \sim (0, \sigma^2 V), V = \text{diag}(w_1^{-1}, \dots, w_n^{-1})$$

$$\begin{aligned} L(\theta) &= \sum_{i=1}^n w_i (y_i - \theta)^2 \\ \partial L / \partial \theta &= -2 \sum_{i=1}^n w_i (y_i - \theta) = 0 \end{aligned}$$

$$\Rightarrow \sum_{i=1}^n w_i y_i - \theta \sum_{i=1}^n w_i = 0$$

$$\therefore \hat{\theta} = \frac{\sum w_i y_i}{\sum w_i}$$

$$\begin{aligned} \text{Var}(\hat{\theta}) &= \text{Var}\left(\frac{\sum w_i y_i}{\sum w_i}\right) = \frac{1}{(\sum w_i)^2} \sum w_i^2 \text{Var}(y_i) \\ &= \frac{1}{(\sum w_i)^2} \sum_{i=1}^n w_i^2 \cdot \frac{\sigma^2}{w_i} \\ &= \frac{\sigma^2 \sum w_i}{(\sum w_i)^2} = \frac{\sigma^2}{\sum w_i} \end{aligned}$$

Textbook Approach:

$$y_i = \theta + \epsilon_i, i=1,2,\dots,n$$

$$X = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \quad V = \begin{bmatrix} \sigma^2/w_1 & 0 & \dots & 0 \\ 0 & \sigma^2/w_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma^2/w_n \end{bmatrix}$$

$$\hat{\theta} = (X'V^{-1}X)^{-1}X'V^{-1}y = \frac{\sum w_i y_i}{\sum w_i}$$

$$\text{Var}(\hat{\theta}) = (X'V^{-1}X)^{-1} \sigma^2 = \frac{\sigma^2}{\sum w_i}$$

Q10.13) 만약 X 의 계수(rank)가 X 의 행의 수보다 작을 때 정규방정식

$$X'V^{-1}X\beta = X'V^{-1}y$$

의 β 에 대한 어떤 임의의 해 (solution)도 $(y - X\beta)'V^{-1}(y - X\beta)$ 를 최소로 값을 보여라.

If $\text{rank}(X) < \# \text{ of rows} \Rightarrow X$ is not full rank
 $\Rightarrow (X'X)$ is not full rank
 $\Rightarrow (X'X)^{-1}$ does not exist

$$\hat{\beta} : \{ \beta : (X'V^{-1}X)\beta = X'V^{-1}y \}$$

$$L(\beta) = (y - X\beta)'V^{-1}(y - X\beta)$$

WTS : $L(\tilde{\beta}) \geq L(\hat{\beta}) \quad \forall \text{arbitrary } \tilde{\beta}$

$$\text{let } \tilde{\beta} = \hat{\beta} + \delta$$

$$\begin{aligned} L(\tilde{\beta}) &= (y - X(\hat{\beta} + \delta))'V^{-1}(y - X(\hat{\beta} + \delta)) \\ &= (y - X\hat{\beta})'V^{-1}(y - X\hat{\beta}) - 2(X\delta)'V^{-1}(y - X\hat{\beta}) + (X\delta)'V^{-1}(X\delta) \\ &= L(\hat{\beta}) - 0 + 2Z'V^{-1}Z \quad \dots (1) \\ &\geq L(\hat{\beta}) \quad \dots (2) \end{aligned}$$

$$\therefore L(\tilde{\beta}) \geq L(\hat{\beta})$$

$$\begin{aligned} (1) \quad &-2(X\delta)'V^{-1}(y - X\hat{\beta}) \\ &= -2\delta'(X'V^{-1}y - X'V^{-1}X\hat{\beta}) = 0 \end{aligned}$$

(2) V is positive definite. $\therefore V^{-1}$ is also positive definite
 $Z'VZ \geq 0 \quad \forall Z \in \mathbb{R}^p$